Analyse des champs lexicaux dans un corpus des frères Goncourt

Morgan RICHARD

20 avril 2026

1 Analyse des champs lexicaux dans un corpus des frères Goncourt

Ce projet porte sur l'analyse d'un corpus de dix romans des frères Goncourt. L'objectif était d'identifier les principaux champs lexicaux qui structurent l'ensemble du corpus, puis d'examiner dans quelle mesure ces régularités peuvent être mises en relation avec une lecture littéraire d'inspiration naturaliste.

1.1 Constitution du corpus

Le corpus étudié est composé des dix œuvres suivantes :

Année	**Titre**
1860	*Charles Demailly*
1861	*Sœur Philomène*
1864	*Renée Mauperin*
1865	*Germinie Lacerteux*
1867	*Manette Salomon*
1869	*Madame Gervaisais*
1877	*La Fille Élisa*
1879	*Les Frères Zemganno*
1882	*La Faustin*
1884	*Chérie*

Table 1 – Œuvres composant le corpus étudié.

Ces textes ont été réunis dans un même corpus afin d'observer les régularités lexicales qui les traversent, mais aussi les différences qui les distinguent. Dans la mesure où un topic modeling appliqué à seulement dix documents aurait produit des résultats peu robustes,

les œuvres n'ont pas été traitées comme dix unités globales, mais segmentées en unités de 300 mots. Cette segmentation a permis d'obtenir 2280 segments, qui constituent les unités d'analyse retenues pour la modélisation thématique.

Ce choix méthodologique répond à un double objectif. D'une part, il augmente le nombre d'unités documentaires disponibles pour la modélisation. D'autre part, il permet de faire apparaître non seulement les différences entre les œuvres, mais aussi les régularités lexicales qui traversent plusieurs textes du corpus.

1.2 Répartition du corpus

La figure 1 présente la distribution du nombre de tokens par œuvre. Elle permet de visualiser les écarts de longueur entre les romans du corpus et de mieux situer les déséquilibres éventuels dans la matière textuelle analysée.

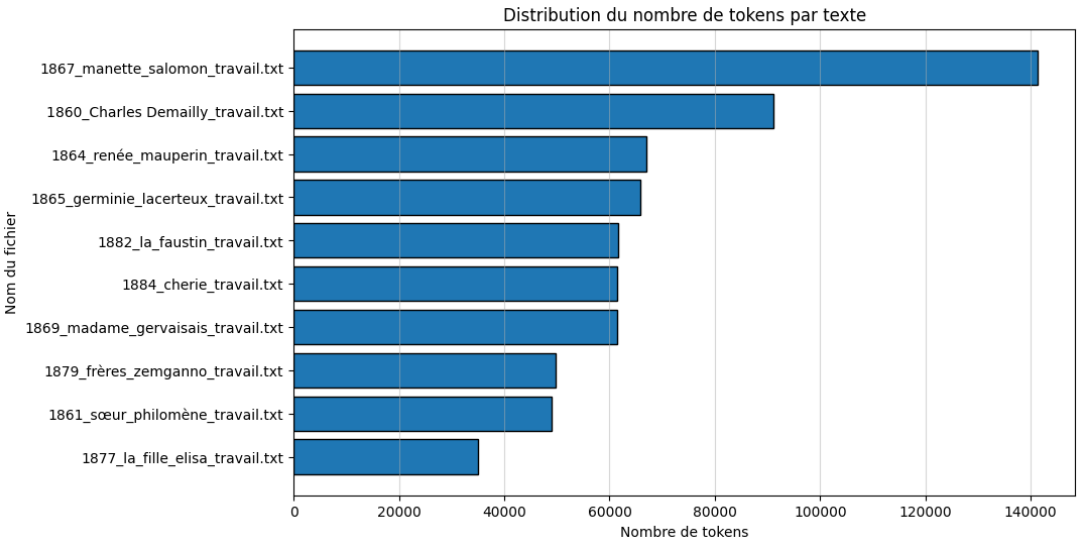

FIGURE 1 – Distribution du nombre de tokens par œuvre du corpus.

On observe que les romans du corpus n'ont pas tous la même longueur. *Manette Salomon* et *Charles Demailly* se distinguent notamment par un volume textuel plus important, tandis que *La Fille Élisa* ou *Sœur Philomène* occupent une place plus réduite. Cette hétérogénéité justifie d'autant plus le choix d'une segmentation en unités de taille fixe.

1.3 Prétraitement des données textuelles

Une phase de prétraitement a ensuite été réalisée à l'aide de la bibliothèque `spaCy`. Le nettoyage du corpus comprenait la suppression des mots-outils, de la ponctuation, des chiffres et des espaces, ainsi que la lemmatisation des formes lexicales. Après plusieurs essais, le choix a été fait de ne conserver principalement que les noms et les adjectifs, afin de faire émerger plus nettement les regroupements lexicaux dominants.

Cette décision s'est révélée méthodologiquement utile : elle a permis d'obtenir des regroupements plus lisibles, en limitant le bruit introduit par certains verbes très fréquents ou par des formulations trop générales. Le corpus prétraité s'est ainsi révélé plus adapté à une lecture centrée sur les grands ensembles lexicaux dominants.

Le protocole finalement retenu repose donc sur une segmentation des textes en unités de 300 mots, un prétraitement avec `spaCy` fondé sur la lemmatisation, la suppression des mots-outils, de la ponctuation et des chiffres, ainsi que la conservation des noms et des adjectifs. La vectorisation a ensuite été réalisée à l'aide d'une matrice TF-IDF paramétrée avec `min_df = 5` et `max_df = 0.8`.

1.4 Choix de la méthode de modélisation

Plusieurs méthodes de topic modeling ont été testées au cours du projet, notamment NMF, LDA avec `Gensim` et BERTopic. Les expérimentations ont montré que, dans le cadre de ce corpus, le modèle NMF produisait les résultats les plus satisfaisants. Les topics obtenus étaient globalement plus cohérents, plus stables et surtout plus facilement interprétables que ceux générés par LDA ou par une approche fondée sur les embeddings.

Le modèle finalement retenu repose sur une factorisation NMF appliquée à une matrice TF-IDF. Plusieurs valeurs du nombre de topics ont été comparées, en particulier 8, 10 et 12. La solution à 10 topics a été conservée, car elle offre le meilleur compromis entre finesse analytique et lisibilité interprétative. Un modèle à 8 topics tendait à fusionner des ensembles lexicaux distincts, tandis qu'un modèle à 12 topics introduisait une fragmentation parfois excessive. Dans ce corpus, NMF à 10 topics s'est révélé le plus satisfaisant, car il produisait des regroupements lexicaux plus cohérents et plus interprétables que les autres modèles essayés.

1.5 Champs lexicaux identifiés

Le modèle retenu a permis de faire émerger dix champs lexicaux principaux dans le corpus. Ils sont résumés dans le tableau 2.

Topic	Champ lexical
1	intériorité, souffrance et pensée
2	paysage et lumière
3	maladie et espace hospitalier
4	famille, enfance et pauvreté
5	argent, affaires et quotidien matériel
6	cirque et performance
7	mariage et sociabilité
8	corps et perception
9	art pictural et atelier
10	théâtre, presse et monde culturel

Table 2 – Champs lexicaux identifiés par le modèle NMF.

Ces résultats montrent à la fois des champs lexicaux transversaux à l'ensemble du corpus et des champs plus étroitement liés à certaines œuvres. Certains ensembles, comme ceux du paysage, du corps ou de l'intériorité souffrante, apparaissent dans plusieurs textes avec une fréquence relativement stable. D'autres, en revanche, sont davantage associés à des univers spécifiques, comme l'hôpital, le cirque, l'atelier pictural ou le monde théâtral.

La distribution globale des segments montre que certains champs lexicaux occupent une place particulièrement importante dans le corpus. Les plus représentés sont *corps et perception* (366 segments), *paysage et lumière* (348 segments), *théâtre, presse et monde culturel* (271 segments) et *mariage et sociabilité* (249 segments). Ces résultats confirment l'importance, dans le corpus, du corps, des milieux sensibles, des espaces sociaux et des formes de représentation.

1.6 Répartition des champs lexicaux par œuvre

Une fois ces champs identifiés, leur répartition a été observée à l'échelle de chaque œuvre. La figure 2 montre que certains champs lexicaux sont présents de manière assez transversale dans plusieurs textes, tandis que d'autres se concentrent davantage dans certains romans. Cette visualisation permet de mieux distinguer les régularités communes au corpus et les spécialisations propres à certaines œuvres.

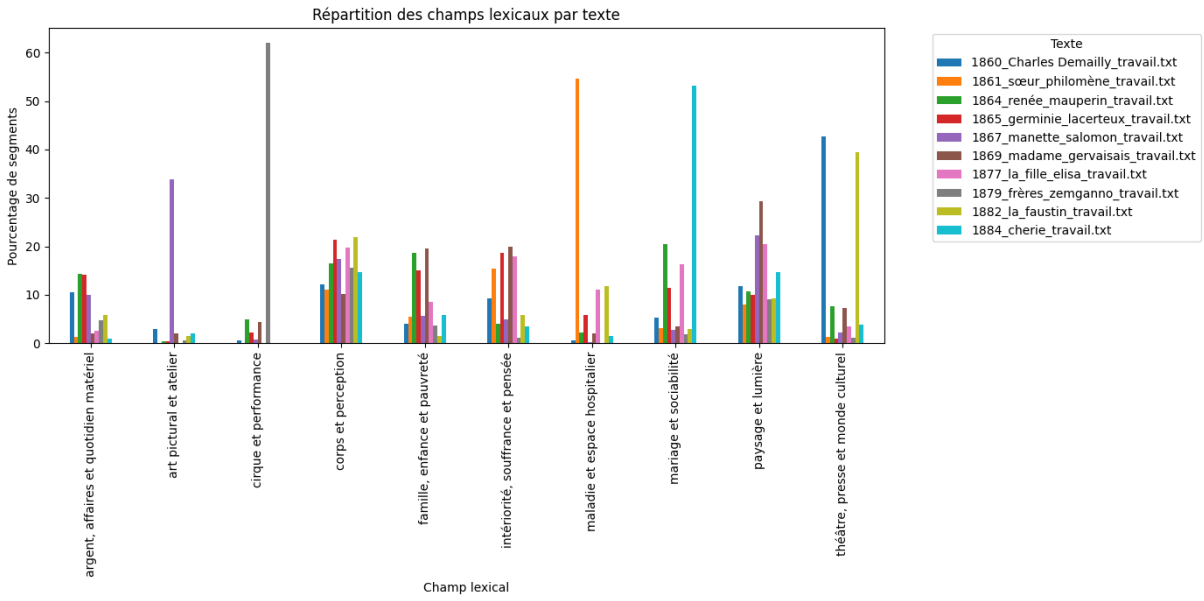

FIGURE 2 – Répartition des champs lexicaux dominants selon les œuvres du corpus.

L'analyse de cette répartition montre notamment la présence récurrente de trois ensembles importants : le paysage, le corps et l'intériorité souffrante. Ces trois champs apparaissent dans plusieurs textes avec une intensité relativement comparable, ce qui suggère l'existence d'un socle lexical commun à l'ensemble du corpus. À l'inverse, d'autres champs, comme l'hôpital, le cirque, l'atelier ou le théâtre, renvoient plus directement à des univers romanesques spécifiques.

1.7 Interprétation littéraire

L'intérêt principal de cette analyse tient au fait qu'elle permet de dégager une structure lexicale d'ensemble du corpus. Les résultats obtenus ne définissent pas à eux seuls une esthétique littéraire, mais ils mettent en évidence plusieurs ensembles sémantiques compatibles avec une lecture naturaliste.

On observe notamment l'importance du corps, du milieu, des conditions matérielles, de la souffrance, des espaces sociaux et des environnements concrets. Cette configuration lexicale renforce l'idée que les textes du corpus accordent une place centrale à la matérialité du monde, à l'inscription sociale des personnages et aux formes de détermination qui pèsent sur eux.

Ainsi, le topic modeling n'est pas ici conçu comme une preuve autonome, mais comme un outil d'exploration capable de faire apparaître des régularités, ensuite réinscrites dans une interprétation littéraire plus large. Il permet d'appuyer l'analyse sur des observations quantitatives tout en maintenant un retour constant aux textes.

1.8 Limites de l'approche

Cette analyse reste néanmoins exploratoire. Les topics extraits par le modèle correspondent à des regroupements lexicaux statistiquement récurrents, et non à des thèmes littéraires au sens strict. Leur interprétation nécessite donc un retour constant aux segments les plus représentatifs et aux œuvres elles-mêmes.

Par ailleurs, les résultats dépendent en partie des choix méthodologiques effectués en amont : taille des segments, nature du prétraitement, seuils de vectorisation et nombre de topics retenu. Ces paramètres influencent la forme finale des champs lexicaux et doivent être pris en compte dans l'interprétation.

1.9 Conclusion

Ce travail montre qu'une méthode de text mining peut être mobilisée de manière utile dans l'analyse d'un corpus littéraire, à condition d'être articulée à une démarche interprétative rigoureuse. Dans le cas des textes des frères Goncourt, l'approche retenue a permis de mettre au jour des champs lexicaux à la fois transversaux et spécifiques, qui éclairent autrement la cohérence du corpus et certaines de ses orientations esthétiques.

Plus largement, ce projet montre qu'une approche computationnelle peut enrichir une lecture littéraire sans s'y substituer. Elle permet de repérer des régularités difficiles à percevoir immédiatement à l'échelle du corpus entier, tout en ouvrant sur une interprétation plus fine des œuvres.

A Annexe méthodologique

Cette annexe résume les principaux choix techniques retenus pour l'analyse.

A.1 Paramètres du protocole

Étape	**Paramètre retenu**
Taille des segments	300 mots
Nombre de segments	2280
Prétraitement	lemmatisation + suppression stopwords/ponctuation/chiffres
Catégories grammaticales conservées	noms et adjectifs
Vectorisation	TF-IDF
`min_df`	5
`max_df`	0.8
Modèle retenu	NMF
Nombre de topics	10
Initialisation NMF	`nndsvda`

Table 3 – Résumé des paramètres méthodologiques.

A.2 Prétraitement et pipeline

Le prétraitement reposait sur une stoplist complémentaire adaptée au corpus, ajoutée aux filtres standards de `spaCy`. À titre d'exemple, les mots suivants ont été exclus car ils étaient trop fréquents ou peu discriminants dans le corpus :

Listing 1 – Extrait de la stoplist complémentaire.

```
stop_word = {

    "bon", "bien", "tout", "toute", "tous", "toutes",
    "grand", "petit", "faire", "aller", "venir", "voir",
    "dire", "savoir", "vouloir", "pouvoir", "prendre",
    "mettre", "donner", "parler", "penser", "avoir", "etre",
    "chose", "fois", "monsieur", "madame", "mademoiselle",
    "cher", "vrai", "renee", "croire", "homme", "femme"

}
```

La fonction de nettoyage appliquée à chaque segment peut être résumée ainsi :

Listing 2 – Fonction de prétraitement des segments.

```
def nettoyer_texte(texte):

    doc = nlp(texte)

    tokens = []

    for token in doc:
        lemme = token.lemma_.lower()

        if (
            not token.is_stop
            and not token.is_punct
            and not token.like_num
            and not token.is_space
            and token.pos_ in {"NOUN", "ADJ"}
            and len(token.lemma_) > 3
            and lemme not in stop_word
        ):

            tokens.append(lemme)

    return "␣".join(tokens)
```

Le pipeline final peut ensuite être résumé par les lignes suivantes :

Listing 3 – Pipeline final de vectorisation et de modélisation.

```
df_segments["texte_nettoye"] = df_segments["texte_segment"].apply(
    nettoyer_texte)

vectorizer = TfidfVectorizer(min_df=5, max_df=0.8)
X = vectorizer.fit_transform(df_segments["texte_nettoye"])
nmf = NMF(n_components=10, init="nndsvda", random_state=42)

W = nmf.fit_transform(X)

df_segments["topic_label"] = W.argmax(axis=1) + 1
df_segments["Champs_lexical"] = df_segments["topic_label"].map(topic_names)
```